Universidad Espíritu Santo®

SEMANA 3 · TUTORÍA SINCRÓNICA

# Modelos de Aprendizaje No Supervisado

Sábado 03/10/2026 · 3 h  MIAR0525 · Maestría en Inteligencia Artificial

# Agenda de hoy

| Tiempo | Bloque | Animaciones |
|---|---|---|
| 0:00–0:10 | Repaso de la semana 2; ¿qué es "correcto" sin etiquetas? | — |
| 0:10–0:50 | K-means y escalamiento | A3.1 · A3.2 |
| 0:50–1:20 | DBSCAN y validación de clusters | A3.3 · A3.4 |
| 1:20–1:30 | Pausa | — |
| 1:30–2:10 | PCA y t-SNE | A3.5 · A3.6 |
| 2:10–2:40 | Anomalías: reglas, Isolation Forest y LOF | A3.7 · A3.8 |
| 2:40–3:00 | Ética de segmentar y marcar personas; Tarea 3 | — |

# Tres errores que conviene no repetir

1. **Elegir hiperparámetros o el umbral con la prueba.** La búsqueda y el umbral se deciden con validación cruzada sobre el entrenamiento; la prueba se usa una vez.
2. **Declarar un ganador por milésimas.** Si dos modelos quedan dentro de una desviación estándar, se prefiere el más simple o explicable.
3. **Decidir con probabilidades sin calibrar.** La regla $p > c/g$ solo funciona si $p$ es una probabilidad creíble (Brier, diagrama de fiabilidad).

# Sin $y$, ¿cómo sabemos si está bien?

**Interna**

Geometría con los mismos datos: inercia, silhouette, Davies-Bouldin, varianza explicada.

**Estabilidad**

¿Sale lo mismo con otra semilla u otra muestra? ARI entre bootstraps.

**Externa y utilidad**

Información que no entró al algoritmo y la pregunta: ¿sirve para decidir algo?

## El algoritmo siempre encuentra algo

K-means devuelve k grupos aunque los datos sean ruido. Una solución no supervisada es una **hipótesis** que hay que validar.

EL MAPA DE LA SEMANA

# Tres tareas y una responsabilidad

**Clustering**

K-means y DBSCAN: segmentos de clientes, zonas geográficas.

**Reducción**

PCA para resumir y comprimir; t-SNE solo para mirar.

**Anomalías**

Isolation Forest y LOF: fraude, intrusiones, fallas.

## La responsabilidad (RDA2)

Segmentar o marcar como "raras" a personas tiene consecuencias. Auditamos la composición por subgrupo antes de usar cualquier resultado.

BLOQUE 1 · 0:10–0:50

# K-means y escalamiento

Centros, distancias y la decisión de cuánto pesa cada variable.

# k centros que minimizan la inercia

$$J = \sum_{j=1}^{k} \sum_{x \in C_j} \|x - \mu_j\|^2$$

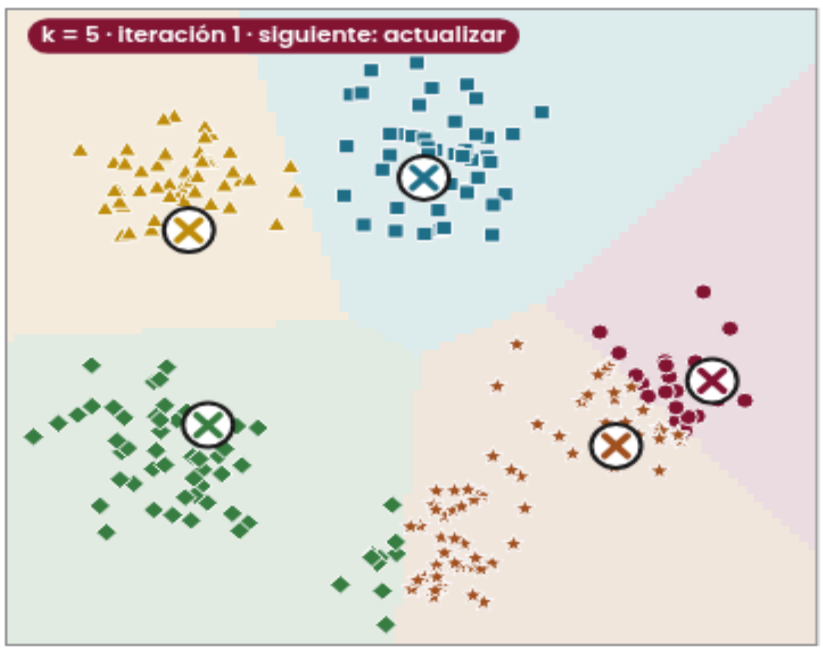
1. **Asignar:** cada punto al centroide más cercano.
2. **Actualizar:** cada centroide a la media de sus puntos.
3. Repetir hasta que nada cambie. $J$ nunca sube.

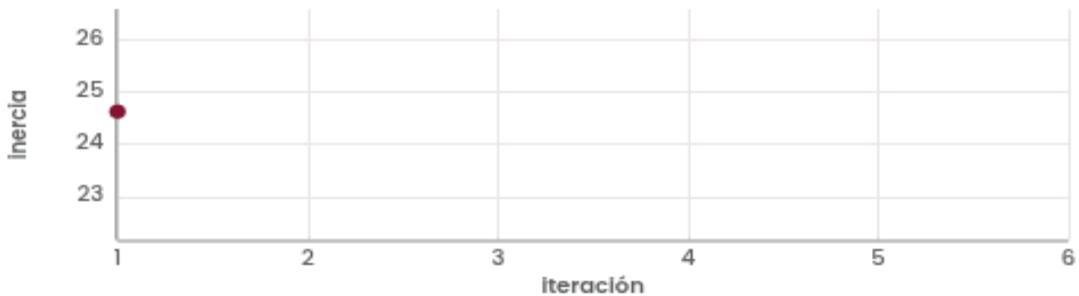
**Pregunta**

Si $J$ nunca sube y el algoritmo siempre converge, ¿por qué dos corridas pueden dar resultados distintos?

ANIMACIÓN A3.1

# Asignar y actualizar




Aquí aparecen la comparación de inicios (escena 3) y el codo con la silhouette (escena 4).

# Óptimos locales y k-means++

- **k-means++:** el primer centro al azar; cada nuevo centro con probabilidad $\propto D(x)^2$ (lejos de los ya elegidos).
- Varias inicializaciones (`n_init`) y se queda la de menor inercia.
- Con `n_init="auto"`, scikit-learn hace una sola corrida con k-means++: conviene fijar `n_init=10`.

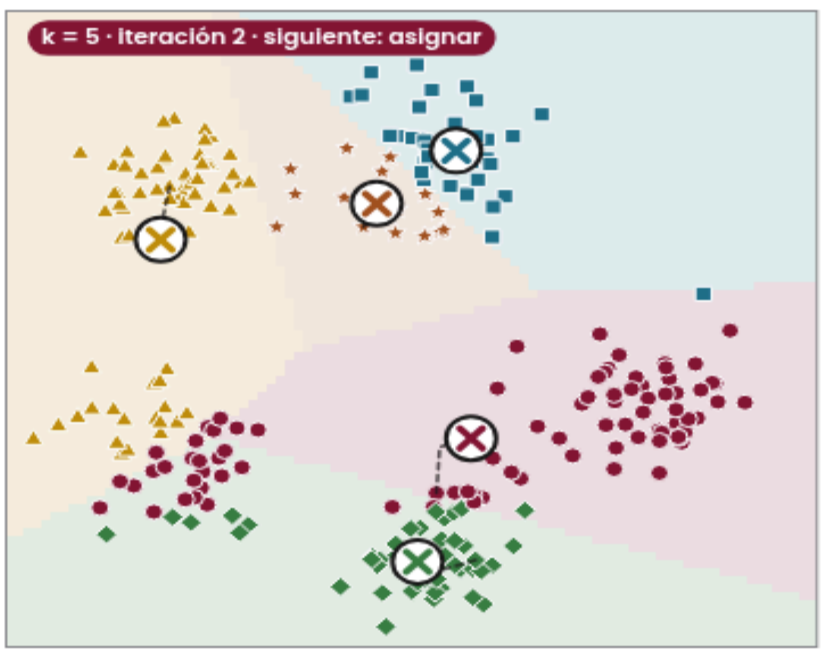
## E3.1 · 5 grupos, 30 corridas

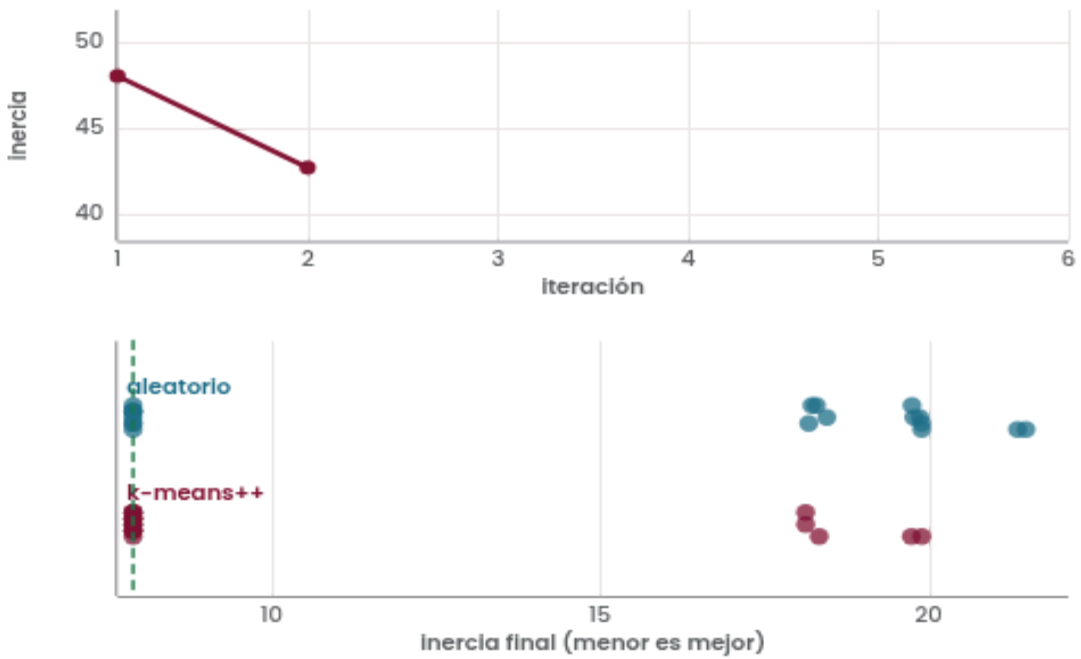
| Inicio | Llega al mejor óptimo | Peor inercia |
|---|---|---|
| Aleatorio | 63 % | 2295.7 |
| k-means++ | **90 %** | 1759.2 |

Mejor inercia en ambos casos: 1035.6.

ANIMACIÓN A3.1

# Veinte inicios aleatorios frente a veinte k-means++



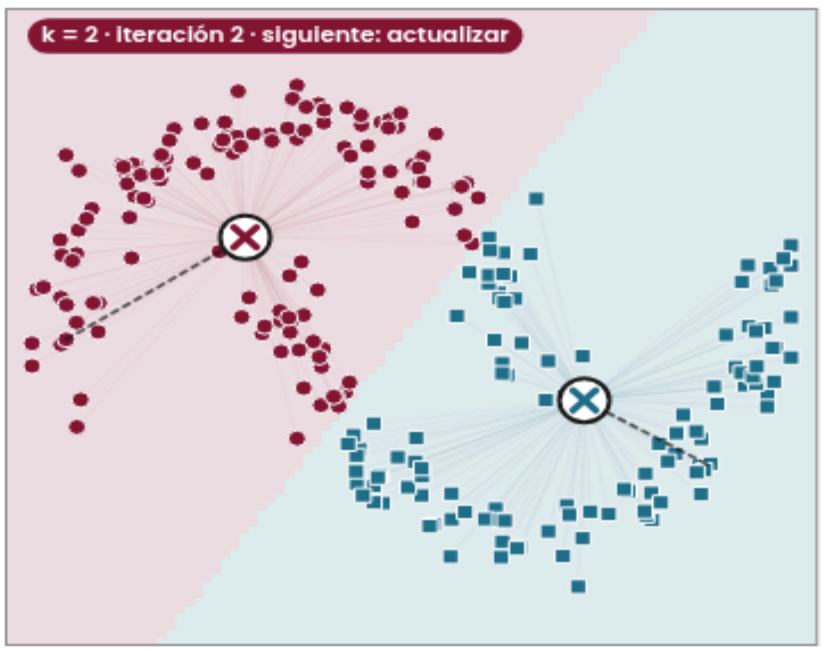



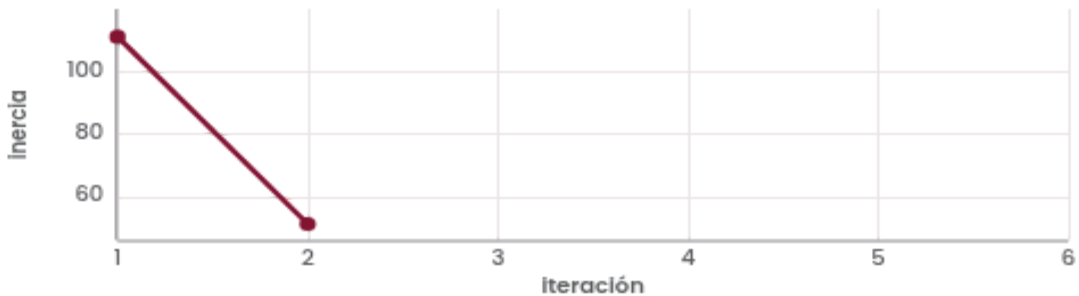
# Codo, silhouette, Davies-Bouldin y estabilidad

| k | Inercia | Silhouette ↑ | Davies-Bouldin ↓ | ARI bootstraps |
|---|---|---|---|---|
| 3 | 3204 | 0.546 | 0.610 | 0.998 |
| 4 | 1856 | 0.590 | 0.537 | 0.993 |
| **5** | 1036 | **0.612** | **0.516** | 0.988 |
| 6 | 935 | 0.553 | 0.749 | 0.898 |
| 8 | 768 | 0.429 | 0.991 | 0.769 |

- La inercia **siempre** baja con k: el codo es una pista, no una prueba.
- Con el k verdadero (5), silhouette máxima, Davies-Bouldin mínimo y solución estable.
- Con k equivocado, cada muestra parte los grupos de otra forma: el ARI cae.
- En datos reales los índices rara vez coinciden: decide también la **utilidad**.

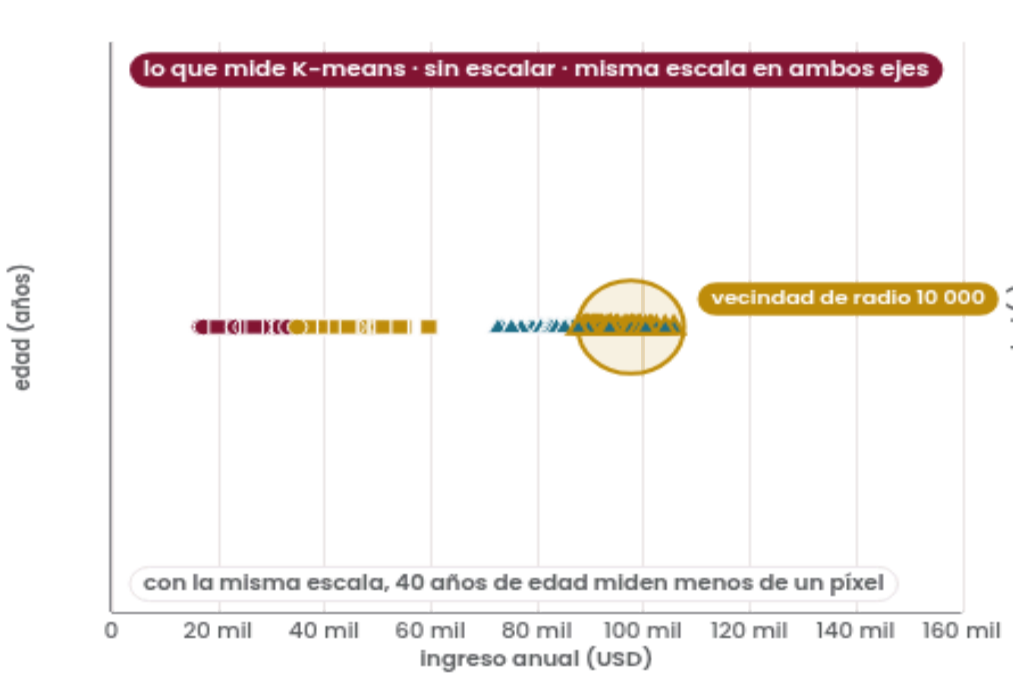
# Grupos convexos, parecidos y sin ruido

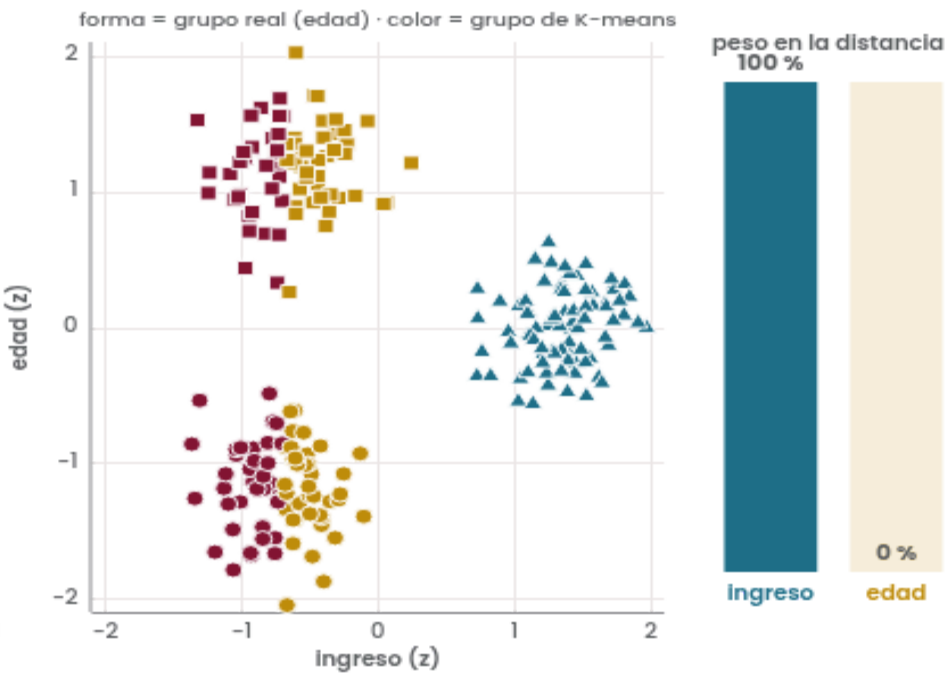



Aquí aparecen la comparación de inicios (escena 3) y el codo con la silhouette (escena 4).

# Ingreso en dólares, edad en años



# La escala es la decisión de cuánto pesa cada variable

- **StandardScaler:** media 0 y desviación 1. Sensible a atípicos.
- **RobustScaler:** mediana e IQR; los extremos no deforman al resto.
- **Log o QuantileTransformer** para montos con cola larga: en E3.1 el saldo va de -8 019 a 102 127 con mediana 448.
- **Categóricas:** one-hot con cuidado, o úsalas para describir los grupos en lugar de formarlos.
- Nunca identificadores ni códigos numéricos como si fueran magnitudes.

Python

```python
from sklearn.cluster import KMeans
from sklearn.pipeline import make_pipeline
from sklearn.preprocessing import QuantileTransformer

seg = make_pipeline(
    QuantileTransformer(n_quantiles=200, random_state=2026)
    KMeans(n_clusters=4, n_init=10, random_state=2026))
etiquetas = seg.fit_predict(X_comportamiento)
```

BLOQUE 2 · 0:50–1:20

# DBSCAN y validación de clusters

Clusters como regiones densas, y cómo saber si una partición es buena.

# Núcleo, borde y ruido

$$N_\varepsilon(p) = \{\, q : d(p,q) \le \varepsilon \,\}$$

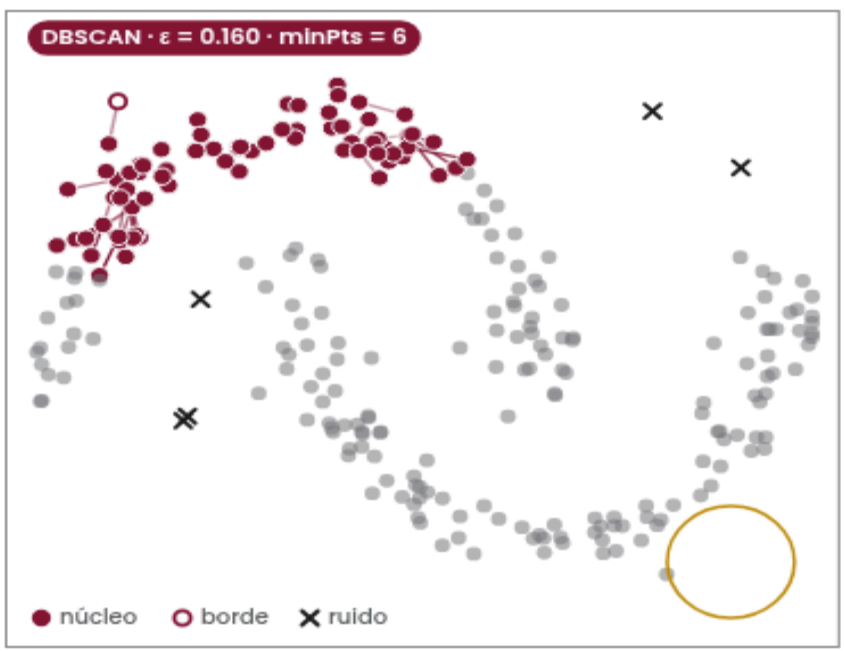
- **Núcleo:** $|N_\varepsilon(p)| \ge$ minPts (contando al propio punto).
- **Borde:** no es núcleo, pero está en la vecindad de un núcleo.
- **Ruido:** todo lo demás (etiqueta -1).
- Un cluster crece en anchura desde un núcleo; los bordes se agregan pero no expanden.

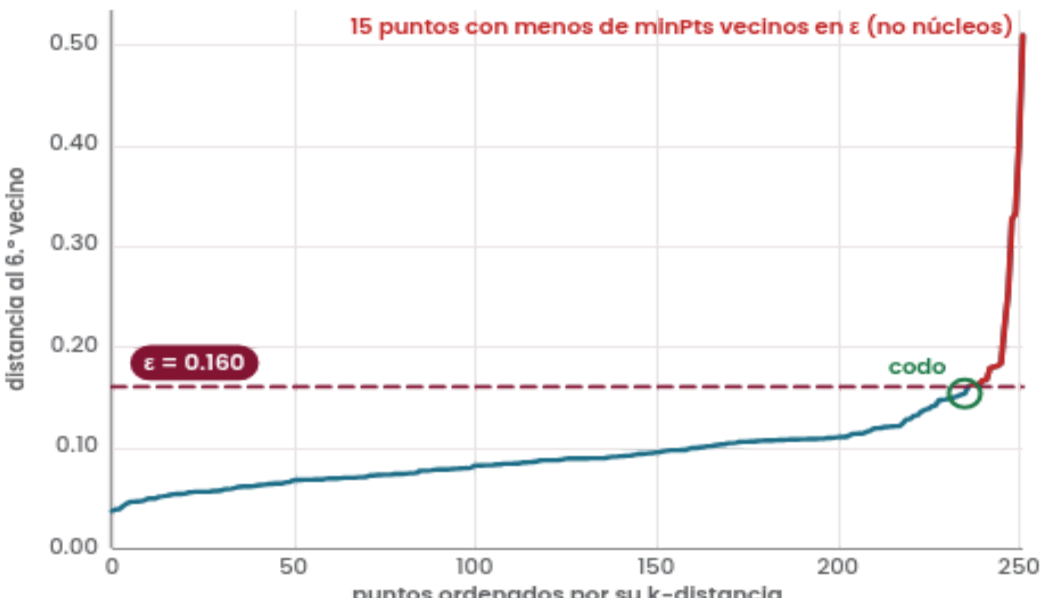
## Ventajas y precio

No pide k, encuentra formas arbitrarias y separa el ruido. A cambio, depende mucho de ε y sufre con densidades distintas.

ANIMACIÓN A3.3

# Un cluster crece de núcleo en núcleo



# El codo de la k-distancia y la distancia haversine

- **k-distancia:** distancia de cada punto a su k-ésimo vecino (k = minPts), ordenada. El codo separa lo denso del ruido. En E3.2: percentil 90 = 0.145, 95 = 0.186 → ε = 0.15.
- **minPts:** al menos la dimensión + 1; el doble con datos ruidosos.
- **Coordenadas:** `metric="haversine"`, [lat, lon] en radianes y ε = km / 6371.

Python

```python
from sklearn.cluster import DBSCAN

coords = np.radians(df[["Latitude", "Longitude"]])
db = DBSCAN(eps=5 / 6371, min_samples=60,
            metric="haversine",
            algorithm="ball_tree").fit(coords)
# California: 22 zonas densas, 29.7 % de ruido
```

# No hay un ε correcto en abstracto

| ε (km) | minPts | Zonas | % ruido |
|---|---|---|---|
| 3 | 120 | 5 | 87.2 |
| 5 | 60 | 22 | 29.7 |
| 10 | 60 | 21 | 16.3 |
| 20 | 30 | 8 | 3.2 |

Con ε = 20 km, una sola zona (de San Diego a Santa Bárbara) reúne el 53 % de los distritos.

¿Barrios, ciudades o regiones? **La pregunta fija ε.**

Estabilidad en submuestras del 80 %: ARI 0.96 (5 km), 0.98 (10 km), 0.94 (20 km).

# Silhouette: ¿más cerca de los tuyos que de los vecinos?

$$s(i) = \frac{b(i) - a(i)}{\max\big(a(i),\, b(i)\big)} \in [-1, 1]$$

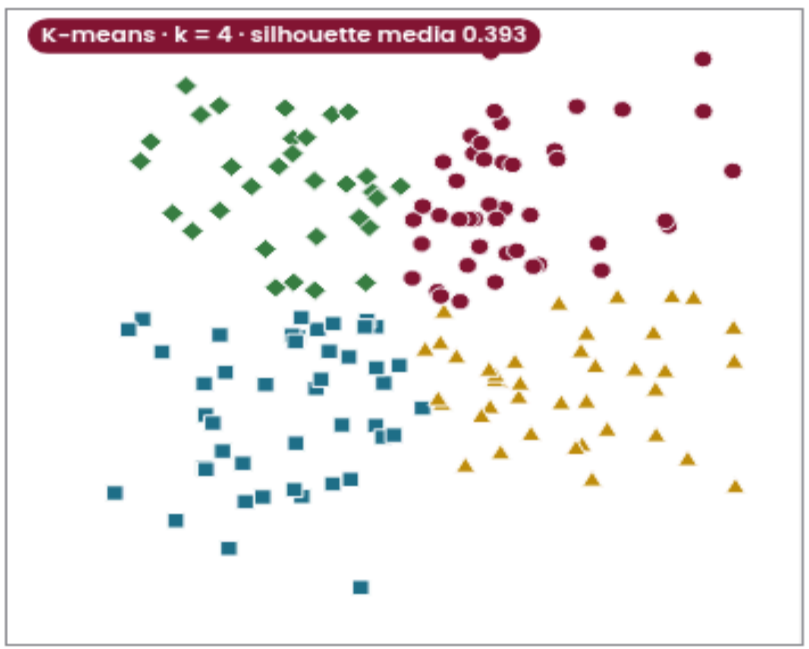
- $a(i)$: distancia media a su propio cluster (cohesión).
- $b(i)$: distancia media al cluster vecino más cercano (separación).
- Cerca de 1: bien ubicado · cerca de 0: en la frontera · **negativa: mal asignado**.

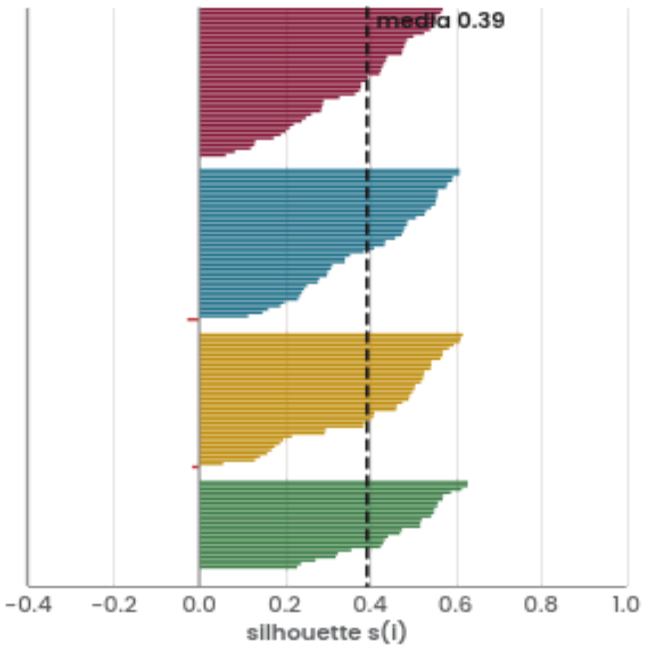
### En la práctica

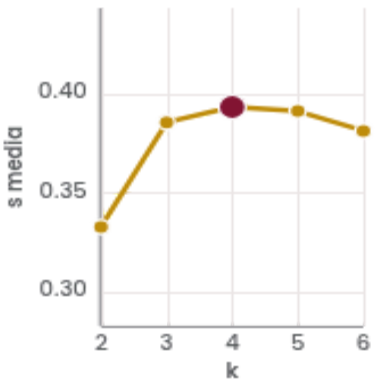
Costo cuadrático en n: con 45 000 clientes, `silhouette_score(..., sample_size=8000)`.

ANIMACIÓN A3.4

# s(i) punto por punto y el gráfico de silhouette




Clic en un punto para ver su a(i), b(i) y s(i). Líneas continuas: su cluster; discontinuas: el cluster vecino.

# Cuatro segmentos que se describen con una frase

| Segmento | % clientes | Saldo mediano | Contratación |
|---|---|---|---|
| Con hipoteca, nunca contactados | 36.4 | 420 | 6.7 % |
| Sin hipoteca ni préstamo | 31.8 | 522 | 13.4 % |
| Contactados en campañas anteriores | 18.3 | 602 | **23.1 %** |
| Con préstamo personal | 13.5 | 238 | 5.9 % |

Silhouette sube hasta k = 8; Davies-Bouldin mejora poco a poco: **los índices no eligen**.

k = 4: estable (ARI 0.88) y útil. La contratación no entró al modelo: **validación externa**.

1:20–1:30

# Pausa · 10 minutos

Al volver: ¿cómo mirar 64 variables a la vez?

BLOQUE 3 · 1:30–2:10

# PCA y t-SNE

Resumir con PCA; mirar con t-SNE, sin creerle de más.

# Las direcciones de máxima varianza

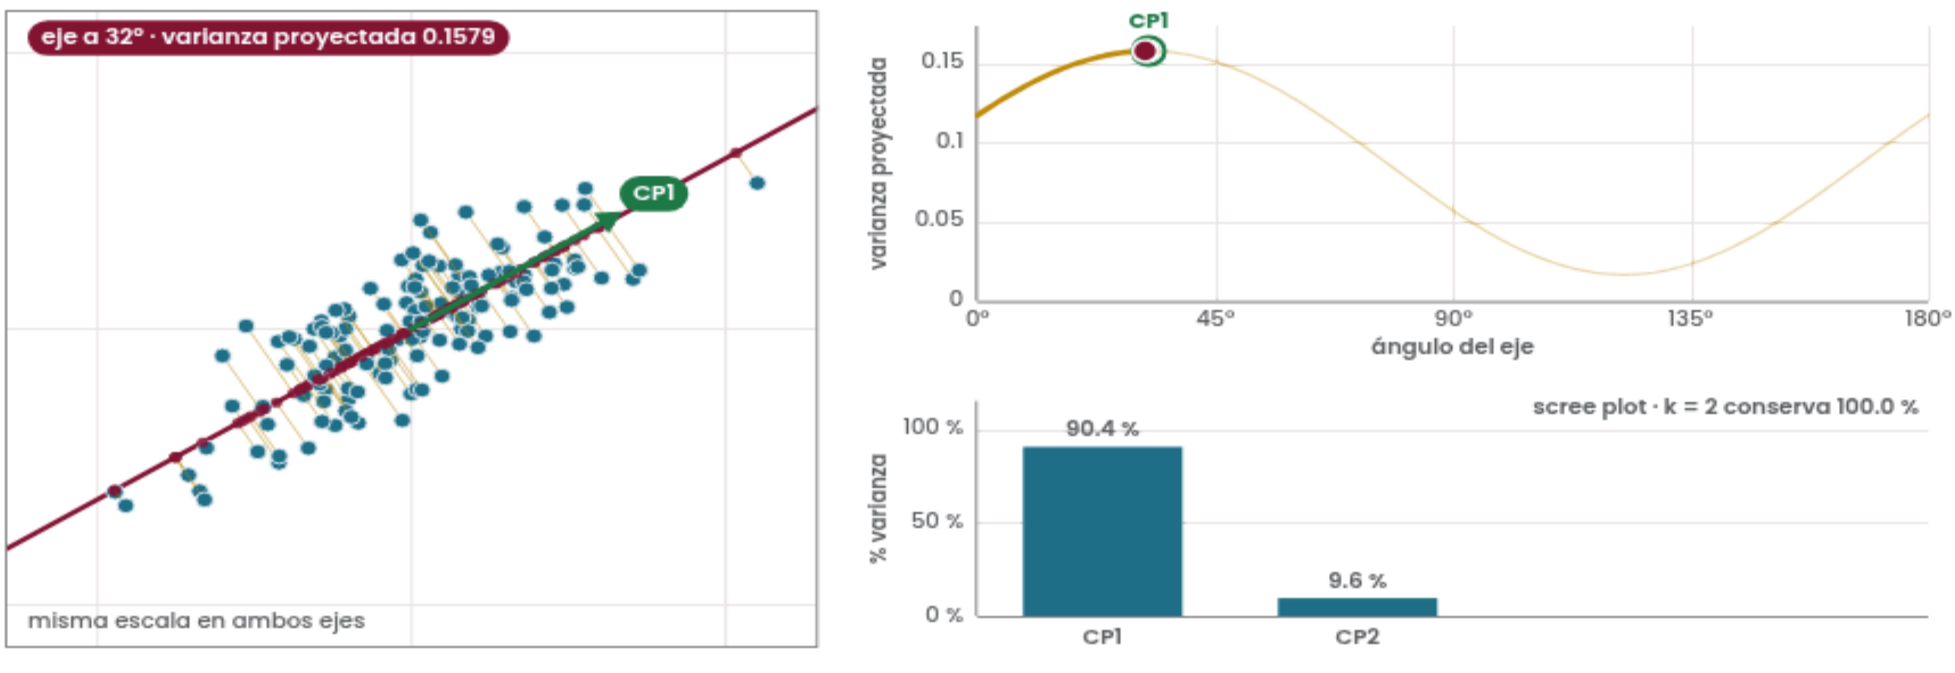
$$X_c = U\Sigma V^\top \qquad Z = X_c V_k \qquad \hat{X} = Z V_k^\top + \bar{x}$$

- Columnas de $V$: las **componentes** (vectores propios de la covarianza).
- Varianza de la componente $j$: $\sigma_j^2/(n-1)$ ; se reporta como proporción.
- Máxima varianza proyectada = **mínimo error de reconstrucción**.

### E3.3 · nube 3D

Varianza: 85.6 % · 13.9 % · 0.6 %. Error de reconstrucción: 1.565 con k = 1, 0.061 con k = 2.

# Un eje que gira hasta capturar la mayor varianza



# Varianza acumulada, codo y el modelo que viene después

- **Olivetti** (4 096 píxeles): 10 / 50 / 150 componentes explican 65.6 / 87.4 / 96.3 %. Con 50 la cara ya se reconoce.
- **digits** (64 píxeles): 2 componentes, 28.5 %; hacen falta 21 para el 90 %.
- `PCA(n_components=0.95)` elige k por varianza.
- Estandariza antes y ajusta PCA **dentro del pipeline**.

| Componentes | Exactitud CV (logística) |
|---|---|
| 5 | 0.815 ± 0.019 |
| 10 | 0.879 ± 0.018 |
| 20 | 0.943 ± 0.012 |
| 30 | 0.955 ± 0.010 |
| 64 (todas) | 0.971 ± 0.006 |

# Que los vecinos sigan siendo vecinos

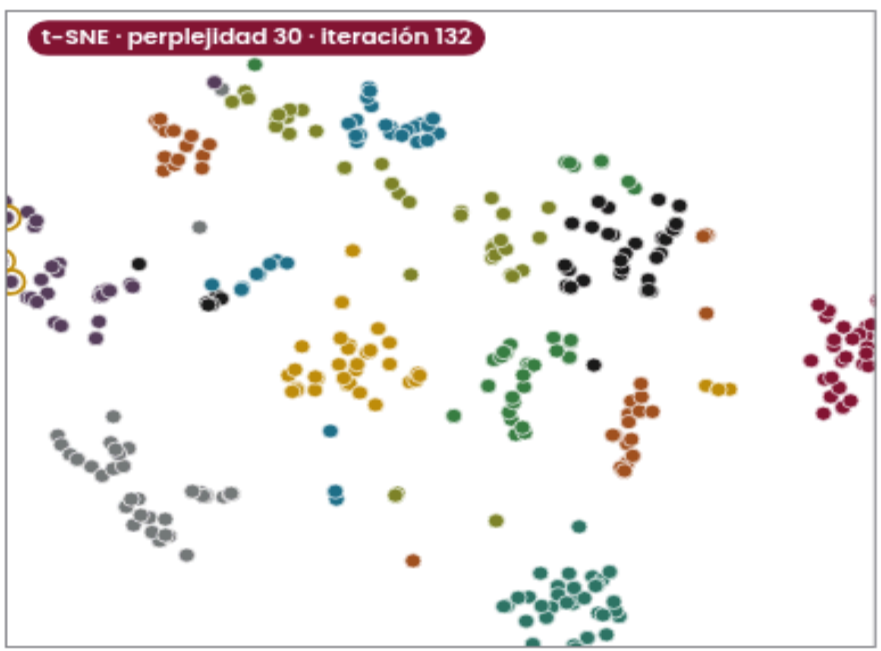
$$p_{j|i} \propto e^{-\|x_i - x_j\|^2 / 2\sigma_i^2} \qquad q_{ij} \propto \left(1 + \|y_i - y_j\|^2\right)^{-1} \qquad \min \mathrm{KL}(P \,\|\, Q)$$

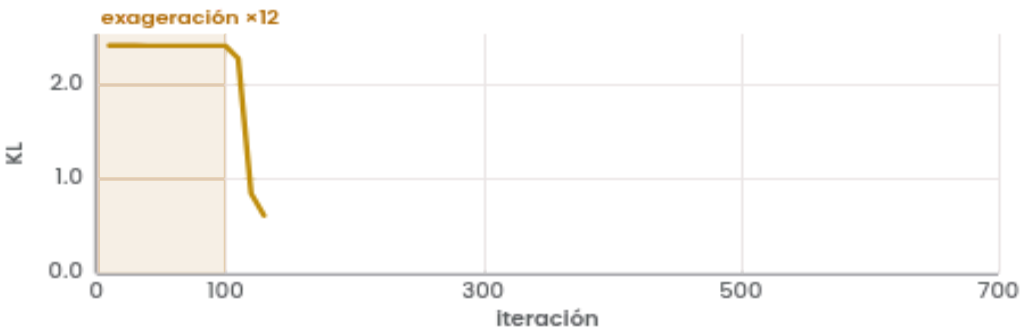
- **Perplejidad** (≈ número efectivo de vecinos) fija cada $\sigma_i$. Valores típicos 5–50; por defecto 30.
- En 2D, una t de Student de colas pesadas: los grupos se separan.
- La KL castiga separar vecinos, no juntar lejanos: conserva lo **local**.

**Pregunta**

Si la KL casi no castiga poner cerca a dos puntos lejanos, ¿qué podemos leer de la distancia entre dos islas?

# 360 dígitos manuscritos se ordenan en islas




el dígito marcado y sus 10 vecinos en el espacio de 64 píxeles



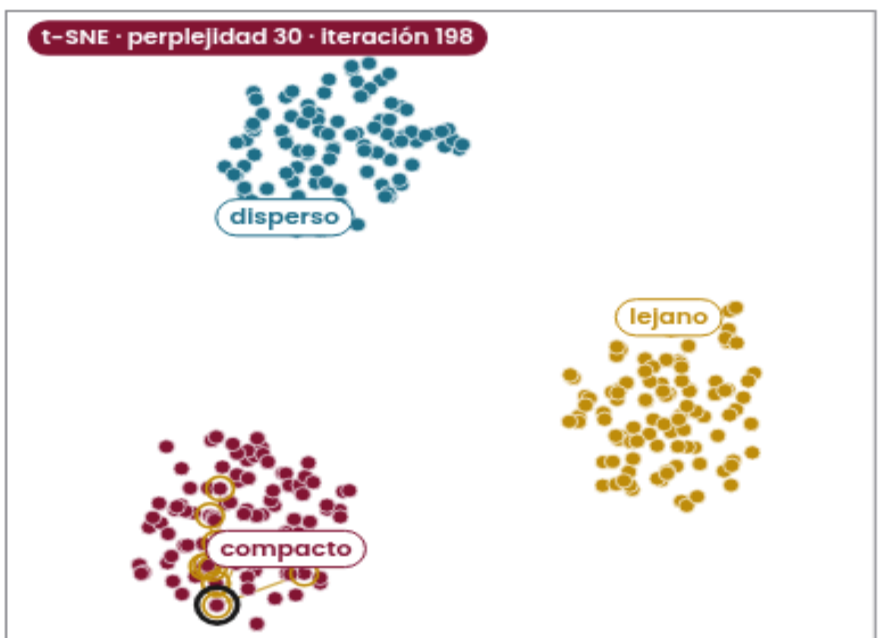

En el mapa, el 11 % de los 10 vecinos reales de cada dígito siguen entre sus 10 vecinos.

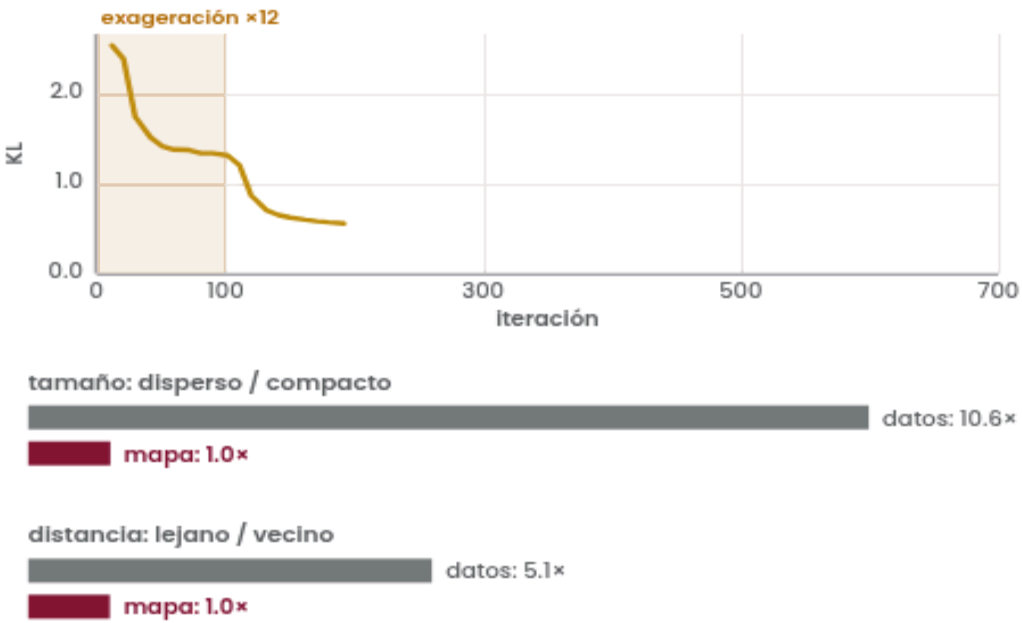
# Tamaños y distancias que no significan nada

| Espacio | Disperso / compacto (tamaño) | Lejano / vecino (distancia) |
|---|---|---|
| Datos originales (5D) | 9.5 | 17.2 |
| PCA 2D | 9.8 | 17.2 |
| **t-SNE 2D** | **1.4** | **2.8** |

En un mapa de t-SNE se lee **quién está cerca de quién**. No se leen tamaños, distancias entre grupos, posición ni densidad.

# Compacto, disperso y lejano: el mapa los iguala



# Para explorar, nunca como variables

1. Al menos **dos perplejidades** (p. ej. 5 y 50) y más de una semilla; `init="pca"`.
2. Escala antes; con muchas variables, reduce primero con PCA a ≈ 50 componentes.
3. `TSNE` no tiene `transform`: sus coordenadas no entran a un modelo.
4. Toda afirmación ("el segmento A es muy distinto del B") se comprueba en el espacio original.

BLOQUE 4 · 2:10–2:40

# Detección de anomalías

Lo raro importa, y cada alerta tiene un costo.

# Empezar por lo simple

- **Atípicos:** el entrenamiento ya contiene anomalías. **Novedades:** se entrena con datos verificados como normales.
- **z-score > 3:** supone normalidad; los atípicos inflan la media y la desviación (enmascaramiento).
- **IQR:** robusto, pero marca la cola de las variables asimétricas.
- Ninguna regla univariada ve anomalías de **combinación**.

| E3.4 · 50 anomalías | Detecta | Falsas alarmas |
|---|---|---|
| z-score > 3 | 33 | 0 |
| IQR 1.5 | 50 | 25 |
| IQR sobre log x | 45 | 4 |

# Lo raro se aísla con pocos cortes

$$s(x) = 2^{-E[h(x)]/c(\psi)} \qquad c(\psi) = 2H(\psi - 1) - \frac{2(\psi-1)}{\psi}$$

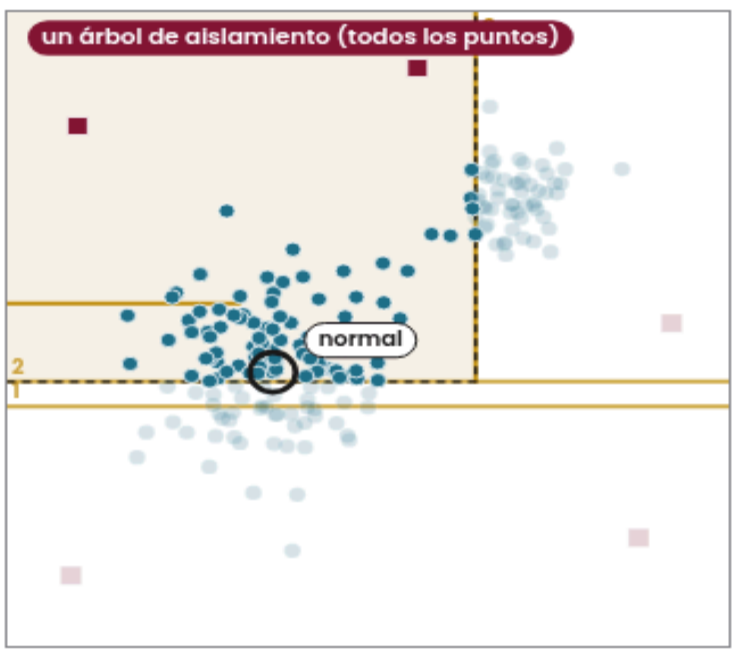
- Cortes al azar (variable y umbral) hasta dejar un punto solo: la **longitud del camino** $h(x)$.
- Muchos árboles, cada uno con una submuestra $\psi$ (256 por defecto).
- $s$ cerca de 1: anomalía; alrededor de 0.5 o menos: normal.

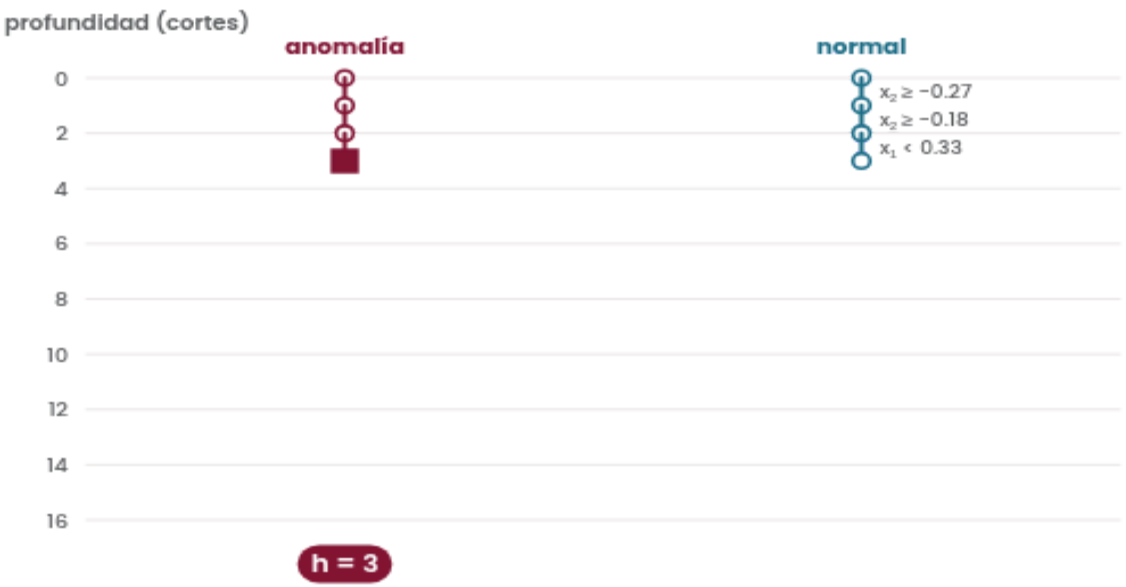
### Ojo con el signo

En scikit-learn, `score_samples` devuelve $-s$: más bajo = más anómalo.

ANIMACIÓN A3.7

# 3 cortes para la anomalía, 14 para un punto normal



# Anómalo respecto de su vecindario

$$\mathrm{lrd}(p) = \left( \frac{1}{k} \sum_{o \in N_k(p)} \max\{\text{k-dist}(o),\, d(p,o)\} \right)^{-1} \qquad \mathrm{LOF}(p) = \frac{\overline{\mathrm{lrd}}(N_k(p))}{\mathrm{lrd}(p)}$$

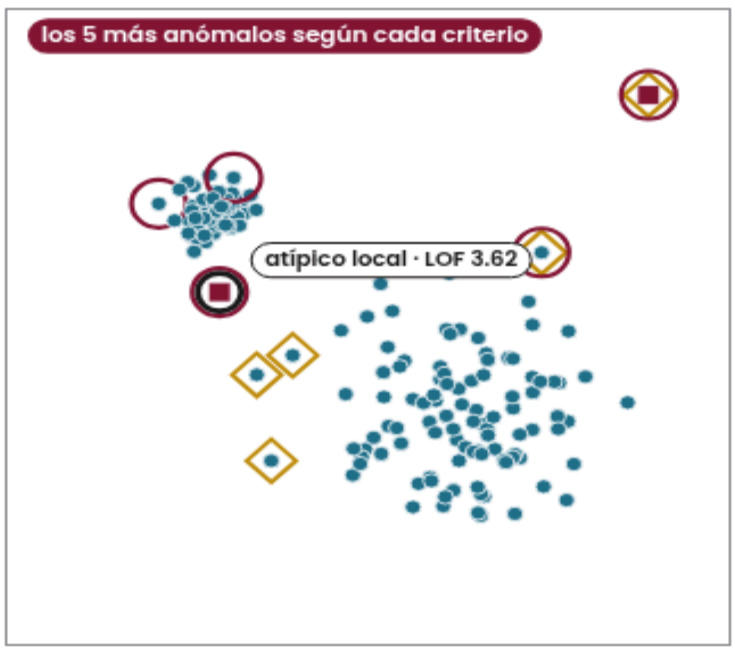
- Densidad local del punto frente a la de sus k vecinos.
- LOF ≈ 1: tan denso como su vecindario. Claramente > 1: atípico local.
- `n_neighbors` (20 por defecto) fija la escala; `novelty=True` para datos nuevos.

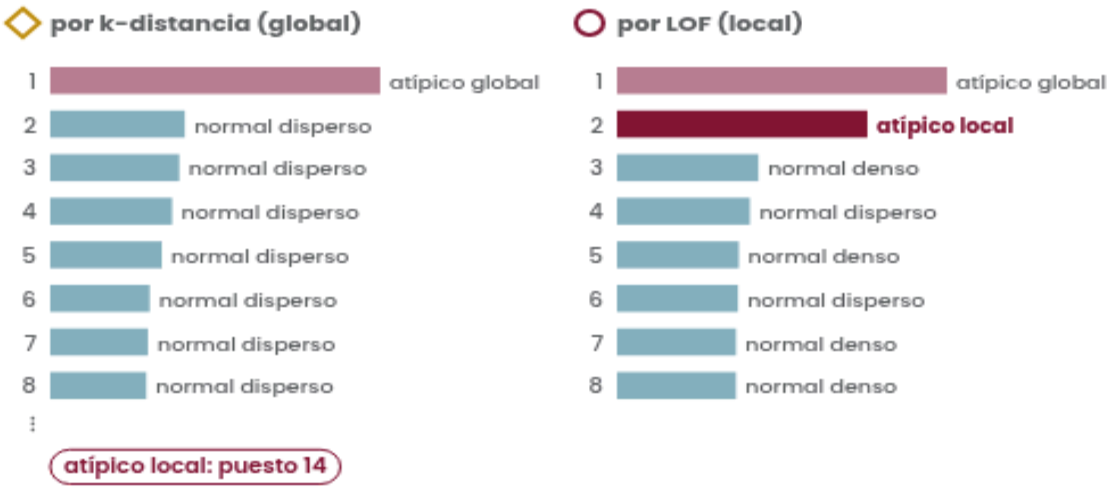
**Pregunta**

Un punto normal de un grupo muy disperso tiene vecinos lejanos. ¿Su LOF es alto?

ANIMACIÓN A3.8

# Puesto 2 por LOF, puesto 14 por distancia



# Lo raro no siempre es lo malicioso

| PR-AUC (azar = 0.034) | Entrenamiento contaminado | Solo tráfico normal |
|---|---|---|
| Máximo \|z\| (baseline) | 0.514 | **0.906** |
| Isolation Forest | 0.441 | 0.714 |
| LOF (k = 35) | 0.075 | 0.553 |

`smurf` (más del 70 % de los ataques): miles de conexiones casi idénticas forman una región **densa** y pasan por normales.

Para un recall del 80 %: 24 falsas alarmas por 10 000 normales con el baseline, **175** con Isolation Forest.

# El umbral lo fija el equipo que revisa

| Alertas por 10 000 conexiones | Recall | Precisión |
|---|---|---|
| 50 | 0.140 | 0.940 |
| 200 | 0.527 | 0.884 |
| 300 | **0.823** | 0.921 |
| 400 | 0.940 | 0.788 |
| 600 | 0.985 | 0.551 |

≈ 340 ataques reales por lote: con menos capacidad, el recall está limitado.

Cada alerta cuesta horas de analista; el exceso produce **fatiga de alertas**.

"Con 300 alertas por lote detectamos el 82 %": así se conversa con el equipo.

BLOQUE 5 · 2:40–3:00

# Ética de segmentar y marcar personas

Sin etiquetas no significa sin decisiones.

# La edad no entró al modelo, pero está en los segmentos

| Segmento | Razón de representación · 60+ |
|---|---|
| Con hipoteca, nunca contactados | **0.26** |
| Sin hipoteca ni préstamo | **1.74** |
| Contactados antes | 1.66 |
| Con préstamo personal | 0.34 |

- Razón = proporción en el segmento / proporción en la población (1 = igual).
- Hipoteca, saldo y contactos previos se relacionan con la etapa de vida: son **proxies**.
- Las variables sensibles se **conservan para auditar**: sin ellas no veríamos el desbalance.
- Priorizar llamadas no es lo mismo que fijar tasas: el riesgo depende del **uso**.

# Ser "raro" no es ser riesgoso

1. **Impacto desigual:** clientes nuevos, otra región o turnos nocturnos son raros por definición y pueden recibir más alertas sin más riesgo.
2. **Mide por grupo:** tasa de alertas y de falsas alarmas, y su razón frente al grupo de referencia.
3. **Estigmatización:** nombres de segmentos y zonas marcadas pueden reproducir exclusiones (*redlining*).
4. **Diseño:** uso previsto documentado, revisión humana antes de actuar y posibilidad de apelar.

TAREA 3 · 20 % · HASTA EL VIE 16/10, 23:59

# Reducción de dimensionalidad, anomalías e impacto por subgrupos

- Datos: **default-of-credit-card-clients** (OpenML 42477): 30 000 clientes, 23 variables + incumplimiento.
- Escalamiento justificado; PCA con varianza y reconstrucción.
- t-SNE solo exploratorio (≥ 2 perplejidades).
- K-means o DBSCAN validado y estable.
- Isolation Forest **y** LOF, comparados, con umbral justificado.
- Composición de clusters y anomalías por sexo, educación y edad, con tasas y razones.
- IA agéntica o de chat permitida, **declarada**.

## Rúbrica (100 pts)

Reproducibilidad 10 · PCA 15 · t-SNE 10 · Segmentación 15 · Anomalías IF/LOF y umbral 15 · **Subgrupos y riesgos éticos 25** · Comunicación 10

TICKET DE SALIDA · 5 MINUTOS

# Antes de irte, responde en el chat

1. Un informe dice que en el mapa de t-SNE el segmento A está "muy lejos" del B. ¿Qué le responderías?
2. Tu Isolation Forest usa `contamination=0.05`. ¿Con qué criterio elegirías el umbral en su lugar?

Universidad Espíritu Santo®

A CONTINUACIÓN · LABORATORIO GUIADO DE 1.5 H

# Ahora, a segmentar clientes de verdad

E3.1 · Nivel 3: Bank Marketing y composición por subgrupo  Tarea 3 · vie 16/10