

SEMANA 4 · UNIDAD 4

Ética, Sesgo y Calidad en el Aprendizaje Automático

 17 – 24 oct 2026
  Clase sincrónica: sábado 17/10 · tutoría 3 h + laboratorio 1.5 h

 48 h: 4.5 ACD · 18 APE · 25.5 AA

RDA1

RDA2

CG-G1

CE-G1

CE-G2

Bibliografía: BB6 · BB7 · BC2 · BC4 · BC5 · BC6 · BC7

MANUAL M4 · TEORÍA DE LA SEMANA

Calidad, equidad, explicabilidad, documentación y monitoreo

Lectura base de la semana 4 (2.5–3 h). Cada sección termina con un enlace **Practica esto** → al nivel exacto del ejercicio o a la animación que la ilustra. Las cifras citadas salen de la ejecución real de los notebooks E4.1–E4.3. Este manual es la base del examen escrito y de la parte de ética del examen práctico.

CONTENIDO

§1	Calidad de datos	§5	Documentación
§2	Sesgo y equidad	§6	Gobernanza
§3	Auditoría con Fairlearn	§7	Monitoreo en producción
§4	Transparencia y explicabilidad	§8	Autoevaluación y lecturas

§1 Calidad de datos

Un modelo no puede ser mejor que sus datos, ni más justo. Antes de entrenar se revisa qué hay en la tabla y cómo llegó ahí.

Faltantes: el mecanismo importa

- **MCAR** (faltan completamente al azar): borrar filas no sesga, solo reduce la muestra.
- **MAR** (dependen de otras variables observadas, p. ej. los jóvenes reportan menos su ingreso): la media de las filas completas se sesga, pero se corrige con esas variables (estratificando, ponderando o imputando con ellas).
- **MNAR** (dependen del propio valor, p. ej. quienes más ganan no lo declaran): con los datos observados no se puede corregir; hace falta información externa o supuestos explícitos.

En la simulación de E4.1 (media verdadera 1 899.6), con MAR la media de las filas completas sube a 2 020.3 y estratificar por edad la devuelve a 1 906.4; con MNAR queda en 1 620.4 y la estratificación solo llega a 1 704.0. Casi nunca se conoce el mecanismo, pero sí se puede comprobar si la tasa de faltantes **cambia entre grupos**: si cambia, no es MCAR. Algunos faltantes son **estructurales** ("no aplica": quien nunca trabajó no tiene ocupación) y se codifican como categoría propia.

Otros problemas frecuentes

- **Duplicados**: exactos o casi exactos. No todo duplicado es error: con variables gruesas, dos personas distintas pueden coincidir. En Adult solo 52 filas son idénticas, pero 6 374 lo son salvo por el peso muestral.
- **Topes y códigos centinela**: valores como 99, 999 o 99 999 que significan "o más" o "desconocido". Una acumulación en el máximo lo delata: en Adult, 244 personas tienen `capital-gain` = 99 999 y el siguiente valor, 3.
- **Ruido e inconsistencias en las etiquetas** y en los registros: en Adult hay 1 mujer registrada como "Husband" y 3 hombres como "Wife".
- **Representación y tasas base**: grupos con pocos cientos de casos (métricas ruidosas) y tasas base distintas (en Adult, 30 % de ingreso alto en hombres frente a 11 % en mujeres), que el modelo aprenderá.
- **Proxies**: variables que codifican un atributo sensible (en Adult, `relationship` casi determina el sexo).
- **Datos obsoletos** y cambios de definición: Adult es de 1994 y su umbral de 50 000 USD es nominal.



A quién borra un `dropna()`

En Adult, borrar las filas con faltantes elimina al 25 % de los mayores de 64 años, al 14 % de las personas asiático-pacíficas y al 9 % de las mujeres, frente al 4–7 % de otros grupos. Limpiar datos es una decisión con efectos por grupo: se documenta y se mide.

La **ficha de datos** (*Datasheet*, Gebru et al., 2021) responde preguntas en siete secciones: motivación, composición, proceso de recolección, preprocesamiento, usos, distribución y mantenimiento. Obliga a escribir para qué **no** debería usarse el conjunto.

Python

```
# ¿MCAR? compara la tasa de faltantes entre grupos
faltan = df.isna().groupby(df["grupo_edad"], observed=True).mean()

# ¿a quién borra dropna?
perdida = 1 - df.dropna()["sexo"].value_counts() / df["sexo"].value_counts()

# ¿acumulación en el máximo (topes o centinelas)?
tope = df["capital_gain"].value_counts().sort_index().tail(2)
```

Practica esto → **E4.1 · Niveles 1 a 4** (mecanismos de faltantes, `reporte_calidad`, Adult y su Datasheet) · **Animación A4.2**

§2 Sesgo y equidad

El sesgo puede entrar en cualquier etapa del ciclo de vida (Suresh y Guttat, 2021): **histórico** (el mundo ya era desigual y las etiquetas lo reflejan), **de representación** (pocos datos de un grupo), **de medición** (un proxy del objetivo, como el gasto en salud en lugar de la necesidad), **de agregación** (un solo modelo para grupos con relaciones distintas), **de evaluación** (un benchmark que no representa a todos) y **de despliegue** (otro contexto u otro uso). Solo una de las seis está en el algoritmo.

Métricas de equidad para clasificadores

Con A el atributo sensible, Y el resultado real y $\hat{Y}$ la predicción:

- **Paridad demográfica:** $P(\hat{Y} = 1 \mid A = a) = P(\hat{Y} = 1 \mid A = b)$: la misma tasa de selección.
- **Igualdad de oportunidades:** la misma TPR, $P(\hat{Y} = 1 \mid Y = 1, A = a) = P(\hat{Y} = 1 \mid Y = 1, A = b)$: quienes merecen el beneficio lo reciben en la misma proporción.
- **Odds igualadas:** la misma TPR y la misma FPR.
- **Paridad predictiva:** la misma precisión, $P(Y = 1 \mid \hat{Y} = 1, A)$: una predicción positiva significa lo mismo en cada grupo (relacionada con la calibración por grupo).

Se reportan como **diferencias** (máximo - mínimo entre grupos) o **razones** (mínimo / máximo). La razón de tasas de selección se compara a veces con la regla de los cuatro quintos (0.8), una referencia de la normativa laboral estadounidense, no un umbral universal.

🔔 No se pueden cumplir todas a la vez

Si los grupos tienen tasas base distintas y el clasificador no es perfecto, no se pueden igualar a la vez la paridad predictiva y las odds igualadas (Chouldechova, 2017; Kleinberg et al., 2016). En E4.2, con tasas base de 31 % y 12 % y un puntaje calibrado, un umbral común da precisión parecida (0.66 y 0.60) pero TPR de 0.38 y 0.15; al igualar la TPR en 0.60 con umbrales por grupo, la precisión se separa (0.55 y 0.37). La elección depende de **a quién perjudica cada error** en el contexto: en un programa de ayuda importa no dejar fuera a quien la necesita (TPR); en una sanción, no señalar a inocentes (FPR).

Practica esto → **E4.2 · Nivel 1** (métricas desde la matriz de confusión) ·

A4.1 métricas y umbrales · **A4.2 fuentes de sesgo**

§3 Auditoría con Fairlearn

`MetricFrame` calcula cualquier métrica global y por grupo, y resume la brecha:

Python

```
from fairlearn.metrics import (MetricFrame, false_positive_rate, selection_rate,
                              true_positive_rate)

mf = MetricFrame(metrics={"selección": selection_rate, "TPR": true_positive_rate,
                          "FPR": false_positive_rate},
                 y_true=y_te, y_pred=pred, sensitive_features=grupo_te,
                 n_boot=200, ci_quantiles=[0.025, 0.975], # intervalos bootstrap
                 random_state=2026)

mf.overall, mf.by_group, mf.difference(), mf.ratio(), mf.by_group_ci
```

Buenas prácticas: reportar el **tamaño** de cada grupo y sus **intervalos**; agrupar categorías con muy pocos casos y decirlo; tratar los valores desconocidos como lo que son (un problema de datos) y auditarlos también. En el modelo de reingreso de E4.2 (AUC 0.64, 40 % de pacientes seleccionados), las TPR de pacientes afroamericanos (0.58) y caucásicos (0.59) tienen intervalos superpuestos; la brecha real está en los pacientes con **raza desconocida**: TPR 0.42 (IC 0.28–0.52). Un registro incompleto se convierte en un trato desigual.

Mitigar y medir el costo

- **Preprocesamiento**: corregir los datos (mejor captura, reponderar, etiquetas mejores). Suele ser lo que ataca la causa.

- **Durante el entrenamiento** (reducciones): `ExponentiatedGradient` reentrena con pesos que castigan la desigualdad y combina modelos al azar; no necesita el grupo al predecir.
- **Poscorrección**: `ThresholdOptimizer` elige umbrales por grupo sobre el puntaje; **necesita el grupo al predecir**, lo que puede no ser legal ni aceptable.

En E4.2, `ThresholdOptimizer` (igualdad de oportunidades) baja la brecha de TPR de 0.17 a 0.06 sin perder exactitud balanceada (0.604), pero sube la selección del 40 % al 48 %: más carga para el programa. `ExponentiatedGradient` no mejora ese caso (exactitud balanceada 0.554, brecha 0.11), y en un ejemplo sintético iguala la TPR bajándola casi a cero en ambos grupos: la **nivelación hacia abajo**. Una métrica de equidad nunca se mira sola.

Python

```
from fairlearn.postprocessing import ThresholdOptimizer

to = ThresholdOptimizer(estimator=modelo, constraints="true_positive_rate_parity",
                        objective="balanced_accuracy_score", prefit=True,
                        predict_method="predict_proba")
to.fit(X_tr, y_tr, sensitive_features=grupo_tr)
pred_mitigada = to.predict(X_te, sensitive_features=grupo_te, random_state=2026)
```

Practica esto → E4.2 · Niveles 2 y 3

(laboratorio del sábado: auditoría de reingreso hospitalario y mitigación)

§4 Transparencia y explicabilidad

- **Importancia por permutación** (global): cuánto empeora la métrica al barajar una variable. Mide la **dependencia del modelo**, no causalidad. En E4.3 domina `had_inpatient_days` (caída de AUC 0.081); tu versión desde cero coincide con `permutation_importance` (correlación de rangos 0.95). Con variables correlacionadas, la importancia se reparte entre ellas: se permutan en grupo.
- **PDP** (global): la predicción promedio al mover una variable. **ICE** (individual): una curva por caso. En E4.3, con la regresión logística todas las curvas ICE de los días de hospitalización suben; con boosting solo el 58 %: el promedio oculta interacciones. Ambas suponen que se puede mover una variable dejando las demás fijas (irreal si están correlacionadas: se extrapola).
- **SHAP** (local): reparte la predicción de un caso entre sus variables, desde el **valor base** (predicción promedio sobre una referencia), con valores de Shapley: el aporte de cada variable promediado sobre todos los órdenes posibles. Es aditivo: $f(x) = E[f(X)] + \sum_j \phi_j$. Para un modelo lineal con variables independientes, $\phi_j = \beta_j(x_j - \bar{x}_j)$ (lo verificas en E4.3).



Malas interpretaciones frecuentes

Leer importancia como causa ("si bajamos X, baja el riesgo"); confiar en un PDP plano sin mirar las ICE; interpretar SHAP sin decir la referencia (con otro conjunto de referencia cambian el valor base y los aportes); explicar un modelo con fuga (la variable más importante puede ser una que no existirá al predecir); usar explicaciones para justificar un modelo que no se validó.

Python

```
from sklearn.inspection import PartialDependenceDisplay, permutation_importance
import shap

pi = permutation_importance(modelo, X_te, y_te, scoring="roc_auc", n_repeats=5,
                           random_state=2026)
PartialDependenceDisplay.from_estimator(modelo, X_te.sample(400), ["time_in_hospital"],
                                       kind="both", centered=True) # PDP + ICE

fondo = shap.maskers.Independent(Z_tr, max_samples=len(Z_tr))
explicador = shap.LinearExplainer(modelo[-1], fondo)
shap.plots.waterfall(explicador(Z_te[[i]])[0])
```

Practica esto → E4.3 · Niveles 1 y 2 · A4.3 permutación · A4.4 PDP e ICE · A4.5 SHAP local

§5 Documentación

- **Model Card** (Mitchell et al., 2019): detalles del modelo, uso previsto (y fuera de alcance), factores, métricas **desagregadas**, datos de evaluación y de entrenamiento, análisis cuantitativos, consideraciones éticas, advertencias y recomendaciones. Documenta un **punto de operación** (umbral) y se versiona con el modelo.
- **Datasheet** (Gebru et al., 2021): la ficha del conjunto de datos (§1).
- **Registro de riesgos**: una tabla viva con cada riesgo, su evidencia, probabilidad, impacto, mitigación, responsable y la función del NIST AI RMF a la que pertenece. En E4.2 incluye, por ejemplo, "el programa llega menos a pacientes con raza desconocida (TPR 0.42 frente a 0.59)".



Una tarjeta vacía es peor que ninguna

Documentar no es llenar un formulario: sin métricas por grupo, sin datos descritos y sin advertencias, la tarjeta da una falsa sensación de control. Se escribe con cifras, se revisa con quienes usan el modelo y se actualiza cuando cambian el umbral, los datos o el uso.

Practica esto → **E4.3 · Nivel 3** (Model Card con métricas desagregadas) ·

A4.7 constructor de Model Card

§6 Gobernanza

El **NIST AI Risk Management Framework 1.0** (NIST, 2023) organiza la gestión de riesgos de la IA en cuatro funciones:

FUNCIÓN	QUÉ HACE	EJEMPLO EN EL CURSO
Gobernar (Govern)	Cultura, políticas, roles, responsables y rendición de cuentas; atraviesa las demás funciones	Quién aprueba usar umbrales por grupo (E4.2: comité de ética)
Mapear (Map)	Contexto, usos previstos, partes afectadas y riesgos	Pacientes repetidos entre entrenamiento y prueba; uso fuera de alcance
Medir (Measure)	Analizar, evaluar y seguir los riesgos con métricas	TPR por grupo con intervalos; PSI; precisión en producción
Gestionar (Manage)	Priorizar, responder, monitorear y comunicar	Plan de monitoreo, reentrenamiento, respuesta a incidentes

El marco describe además las características de una IA confiable: válida y fiable; segura; protegida y resiliente; responsable y transparente; explicable e interpretable; respetuosa de la privacidad; y justa, con los sesgos dañinos gestionados. Es voluntario y no reemplaza la normativa de cada país; sirve como lenguaje común para organizar el trabajo.

Practica esto → **E4.2 · Nivel 4** (informe de auditoría y registro de riesgos)

§7 Monitoreo en producción

- **Drift de datos** (cambia la distribución de las entradas): se detecta de inmediato comparando con la referencia. El $PSI = \sum_i (p_i - q_i) \ln(p_i / q_i)$ por intervalos (regla práctica: < 0.1 estable, $0.1-0.25$ revisar, > 0.25 actuar) y la prueba de **Kolmogórov-Smirnov** para variables numéricas (con miles de datos detecta diferencias minúsculas: el valor p dice si hay diferencia, no si importa).
- **Drift de concepto** (cambia la relación entre entradas y resultado): no se ve en las entradas; solo aparece al medir el desempeño cuando llegan las etiquetas, a veces con semanas de

retraso.

- **Métricas por grupo en el tiempo**, con la frecuencia que permita su tamaño (los grupos pequeños, por trimestre).

En la simulación de E4.3, durante tres meses de drift de datos el PSI de las hospitalizaciones previas llega a 0.11 y la tasa de seleccionados sube del 44 % al 53 %, con la precisión estable; en los tres meses siguientes el PSI se queda quieto, pero el reingreso real baja del 13 % al 10 % y la precisión cae a 0.14: drift de concepto. El recall incluso sube: mirar una sola métrica engaña.

Un **plan de monitoreo** define qué se mide, cada cuánto, con qué umbral, quién responde y qué hace (analizar, reentrenar, revertir, detener). Los incidentes se registran y se revisan (BC2). El **registro de modelos** de MLflow guarda cada versión con sus métricas, su Model Card y su plan, para comparar y volver atrás.

Python

```
import mlflow

mlflow.set_tracking_uri("sqlite:///mlflow.db")
with mlflow.start_run(run_name="logistica-balanceada"):
    mlflow.log_metric("auc_prueba", auc)
    mlflow.log_text(tarjeta_markdown, "model_card.md")
    info = mlflow.sklearn.log_model(modelo, name="modelo",
                                    registered_model_name="reingreso-diabetes",
                                    input_example=X_te.head(3))
version = info.registered_model_version
cargado = mlflow.sklearn.load_model(f"models:/reingreso-diabetes/{version}")
```

Practica esto → E4.3 · Niveles 3 y 4

(drift simulado, plan de monitoreo y registro en MLflow) · **A4.6 drift y monitoreo**

§8 Autoevaluación y lecturas

▼ **1.** La tasa de faltantes de "ocupación" es 12 % en jóvenes, 3 % en adultos y 24 % en mayores de 64. ¿Puedes eliminar esas filas sin más?

No: los faltantes no son MCAR, y borrarlos cambia la composición por edad (en Adult se pierde una de cada cuatro personas mayores). Documenta el mecanismo probable, trata los faltantes estructurales como categoría y mide el efecto de la limpieza por grupo.

▼ **2.** Un modelo tiene la misma precisión para dos grupos, pero la TPR es 0.40 en uno y 0.16 en el otro. ¿Es justo?

Cumple la paridad predictiva, no la igualdad de oportunidades. Con tasas base distintas no se pueden cumplir ambas; decide según a quién perjudica el falso negativo en ese contexto y documenta la elección.

▼ **3.** La TPR de un grupo de 55 casos positivos es 0.42 y la de otro de 2 579 es 0.59. ¿Qué agregas antes de concluir?

Intervalos de confianza (bootstrap, `n_boot` en `MetricFrame`) y el tamaño de cada grupo. Si los intervalos no se superponen, la brecha es creíble; si se superponen, hay que reunir más datos.

▼ **4.** `ThresholdOptimizer` iguala la TPR sin perder exactitud balanceada. ¿Lo despliegas?

Solo después de revisar su costo (en E4.2, 8 % más de pacientes seleccionados), que usa el atributo sensible al decidir (consulta legal y ética) y que la causa (registros incompletos) se atiende en los datos.

▼ **5.** El PDP de una variable es plano. ¿Concluyes que no influye?

No. Mira las curvas ICE: puede haber efectos opuestos que se cancelan en el promedio (interacción). Y revisa si las combinaciones evaluadas existen en los datos.

▼ **6.** El PSI de todas las variables está por debajo de 0.05 y la precisión del modelo cayó 4 puntos. ¿Qué pasa?

Probablemente drift de concepto: cambió la relación entre las variables y el resultado, no la población. Se detecta con el desempeño cuando llegan las etiquetas; se analiza la causa y se reentrena con datos recientes.

Lecturas de la semana

- **BB6** · Molnar (2025), Interpretable Machine Learning: importancia por permutación, PDP, ICE y SHAP.
- **BB7** · Barocas, Hardt y Narayanan (2023), Fairness and Machine Learning: clasificación y criterios de equidad.
- **BC2** · Huyen (2022), *Designing Machine Learning Systems*: cambio de distribución y monitoreo.
- **BC4** · Mitchell et al. (2019), Model Cards for Model Reporting.
- **BC5** · NIST (2023), AI RMF 1.0: resumen y funciones del núcleo.
- **BC6** · Gebru et al. (2021), Datasheets for Datasets.
- **BC7** · MLflow Documentation: Model Registry.



Cómo te prepara para los exámenes

El examen escrito (sáb 24/10) incluye 7 ítems de esta unidad: lectura de un `MetricFrame`, elección de la métrica de equidad según el contexto, interpretación de PDP/ICE y SHAP, drift de datos frente a drift de concepto. El examen práctico pide auditoría con `MetricFrame`, explicabilidad global y local, Model Card, Datasheet, plan de monitoreo y registro de riesgos para tu variante de ACS Income.