

SEMANA 4 · TUTORÍA SINCRÓNICA

Ética, Sesgo y Calidad en el Aprendizaje Automático

Sábado 17/10/2026 · 3 h MIAR0525 · Maestría en Inteligencia Artificial

Agenda de hoy

Tiempo	Bloque	Animaciones
0:00–0:10	Repaso de la Tarea 3: lo que revelaron los subgrupos	—
0:10–0:40	Calidad de datos y fichas de datos	—
0:40–1:20	Sesgo, métricas de equidad y mitigación	A4.1 · A4.2
1:20–1:30	Pausa	—
1:30–2:10	Explicabilidad y Model Cards	A4.3 · A4.4 · A4.5 · A4.7
2:10–2:35	Gobernanza y monitoreo	A4.6
2:35–3:00	Instrucciones de los exámenes	—

Lo que revelan los subgrupos

- 1 **Sin la variable sensible no hay neutralidad.** Los segmentos quedaron con composiciones muy distintas por edad o sexo: las variables de comportamiento funcionan como proxies.
- 2 **Las anomalías no se reparten igual.** Lo "raro" coincide con grupos pequeños o con perfiles distintos, no necesariamente riesgosos.
- 3 **Medir exige conservar el atributo.** Sin sexo, educación o edad no se puede auditar; se guardan para auditar, no para decidir.

Del dato al modelo en producción

Datos

Calidad, faltantes, representación y la ficha de datos.

Modelo

Equidad por grupo, mitigación y explicabilidad.

Producción

Model Card, gobernanza (NIST AI RMF) y monitoreo.

El hilo conductor

Cada decisión técnica tiene efectos por grupo. Se miden, se documentan y alguien responde por ellas.

BLOQUE 1 · 0:10–0:40

Calidad de datos

Antes de entrenar: qué hay en la tabla y cómo llegó ahí.

MCAR, MAR y MNAR

- **MCAR:** al azar. Borrar filas no sesga.
- **MAR:** depende de otras variables observadas. Se corrige con ellas.
- **MNAR:** depende del propio valor. No se corrige con los datos.
- Si la tasa de faltantes **cambia entre grupos**, no es MCAR.

E4.1 · media verdadera 1 899.6	Filas completas	Estratificada
MCAR	1 906.6	1 904.1
MAR (edad)	2 020.3	1 906.4
MNAR (ingreso)	1 620.4	1 704.0

Limpiar también discrimina

Grupo de edad	Falta ocupación	Filas que borra <code>dropna()</code>
17-24	12.3 %	13.3 %
35-44	2.1 %	4.1 %
65+	24.0 %	25.2 %

- También borra el 14 % de las personas asiático-pacíficas y el 9 % de las mujeres.
- Parte de los faltantes son **estructurales**: quien nunca trabajó no tiene ocupación ("no aplica").
- Toda limpieza se documenta y se mide por grupo.

Lo que un `describe()` no muestra

- **Topes y centinelas:** 244 personas con `capital-gain` = 99 999 (el siguiente valor tiene 3); 137 con 99 horas; 55 con 90 años.
- **Duplicados:** 52 exactos, pero 6 374 idénticos salvo el peso muestral. No todo duplicado es error.
- **Redundancias:** `education` y `education-num` dicen lo mismo.
- **Proxies:** `relationship` casi determina el sexo ("Husband": 19 715 hombres y 1 mujer).
- **Tasas base:** ingreso alto 30 % en hombres y 11 % en mujeres.

Python

```
rep = reporte_calidad(adult, grupo="sex")
#                                alertas
# age                            acumulación en el máximo (90)
# capital-gain                   acumulación en el máximo (99999)
# hours-per-week                 acumulación en el máximo (99)
# native-country 2 categoría(s) con < 20 filas
```

Siete preguntas antes de usar un conjunto

- | | |
|---|--|
| 1 Motivación · ¿para qué se creó? | 1 Usos · ¿y para qué <i>no</i> ? |
| 2 Composición · ¿quién está y quién falta? | 2 Distribución · ¿bajo qué condiciones? |
| 3 Recolección · ¿cómo y cuándo? | 3 Mantenimiento · ¿quién lo actualiza? |
| 4 Preprocesamiento · ¿qué se limpió? | |


Adult: útil para enseñar; inapropiado para decidir créditos o salarios hoy. Su sucesor, ACS Income, es el conjunto del examen práctico.

BLOQUE 2 · 0:40–1:20

Sesgo y equidad

Seis puertas de entrada y cuatro formas de medir.


El sesgo no nace solo en el modelo




Cuatro criterios

Criterio	Se iguala entre grupos	Pregunta que responde
Paridad demográfica	$P(\hat{Y} = 1 \mid A)$	¿Todos reciben la decisión positiva en la misma proporción?
Igualdad de oportunidades	TPR	¿Quien lo merece lo recibe por igual?
Odds igualadas	TPR y FPR	¿Los dos errores son iguales?
Paridad predictiva	precisión	¿Una predicción positiva significa lo mismo?

Mismo puntaje, mismo umbral, tasas distintas



Con tasas base distintas, hay que elegir



¿A quién perjudica cada error?

Programa de ayuda

El falso negativo deja sin apoyo a quien lo necesita → **TPR** (igualdad de oportunidades).

Sanción o sospecha

El falso positivo señala a un inocente → **FPR**.

Priorizar con un puntaje

El número debe significar lo mismo para todos → **calibración y precisión** por grupo.

La elección se discute con las personas afectadas y se escribe en la Model Card.

Auditar con Fairlearn

Python

```
from fairlearn.metrics import (MetricFrame,
                              true_positive_rate)

mf = MetricFrame(metrics={"TPR": true_positive_rate},
                 y_true=y_te, y_pred=pred,
                 sensitive_features=raza_te,
                 n_boot=200, ci_quantiles=[0.025, 0.975],
                 random_state=2026)
mf.by_group, mf.difference(), mf.by_group_ci
```

Raza	TPR	IC 95 %	Positivos
Afroamericana	0.58	0.54–0.62	662
Caucásica	0.59	0.57–0.61	2 579
Otra	0.56	0.48–0.65	111
Desconocida	0.42	0.28–0.52	55

La brecha está en los registros incompletos: un problema de calidad de datos se vuelve de equidad.

Tres lugares para intervenir

- **Datos:** mejor captura, reponderar, mejores etiquetas. Ataca la causa.
- **Entrenamiento:**
ExponentiatedGradient (no usa el grupo al predecir).
- **Poscorrección:**
ThresholdOptimizer (umbral por grupo; **sí** usa el grupo al predecir).

E4.2	Exactitud bal.	Brecha TPR	Seleccionados
Sin mitigar	0.604	0.173	40 %
ThresholdOptimizer	0.604	0.059	48 %
ExponentiatedGradient	0.554	0.114	37 %

Cuidado con la **nivelación hacia abajo**: igualar empeorando a todos también "cumple" la métrica.

1:20–1:30

Pausa · 10 minutos

Al volver: ¿por qué el modelo decidió eso?

BLOQUE 3 · 1:30–2:10


Explicabilidad y documentación

Dependencia, no causalidad; y todo por escrito.



Global, individual y local

Método	Alcance	Responde	Cuidado con
Permutación	global	¿De qué depende el modelo?	variables correlacionadas
PDP	global	¿Cómo cambia la predicción media?	el promedio oculta interacciones
ICE	individual	¿Y para cada caso?	extrapolación
SHAP	local	¿Por qué este caso recibió este número?	el conjunto de referencia

Barajar una columna y medir la caída



El promedio puede ocultar



Repartir la predicción entre las variables


$$f(x) = E[f(X)] + \sum_j \phi_j \quad \phi_j = \text{aporte medio de } j \text{ sobre todos los órdenes}$$

- **Aditivo:** los aportes suman la diferencia con el valor base.
- **Local:** explica un caso; la importancia global promedia muchos.
- Modelo lineal con variables independientes: $\phi_j = \beta_j(x_j - \bar{x}_j)$ (lo verificas en E4.3).

Pregunta

Si cambias el conjunto de referencia, ¿cambia la explicación de un mismo paciente?

Del promedio a la predicción de un paciente



Cinco malas interpretaciones

- 1 "Es la variable más importante, así que si la cambiamos, cambia el resultado" (causalidad).
- 2 "El PDP es plano, no influye" (sin mirar las ICE).
- 3 "SHAP dice que la edad sumó 10 puntos" (sin decir frente a qué referencia).
- 4 Explicar un modelo con fuga: la variable estrella no existirá al predecir.
- 5 Usar explicaciones bonitas para justificar un modelo que no se validó.


La ficha técnica del modelo

- Detalles · uso previsto y fuera de alcance · factores
- **Métricas desagregadas** en un punto de operación (umbral)
- Datos de entrenamiento y evaluación (enlace a la Datasheet)
- Consideraciones éticas · advertencias y recomendaciones

Una tarjeta vacía es peor que ninguna

Da una falsa sensación de control. Se escribe con cifras, se revisa con quienes usan el modelo y se versiona.

Una tarjeta que se arma con métricas en vivo



BLOQUE 4 · 2:10–2:35

Gobernanza y monitoreo

Quién responde, qué se vigila y qué se hace cuando algo cambia.

Cuatro funciones

Función	Qué hace
Gobernar	Políticas, roles, responsables; atraviesa todo
Mapear	Contexto, usos, afectados y riesgos
Medir	Métricas y seguimiento de los riesgos
Gestionar	Priorizar, responder y monitorear

IA confiable, según el marco

Válida y fiable · segura · protegida y resiliente · responsable y transparente · explicable · respetuosa de la privacidad · justa, con los sesgos dañinos gestionados.

Un registro de riesgos con evidencia

Riesgo	Función	Evidencia	Mitigación	Responsable
El programa llega menos a pacientes con raza desconocida	Medir	TPR 0.42 frente a 0.59	Mejorar la captura; revisión humana	Calidad de datos clínicos
La mitigación aumenta la carga	Gestionar	Selección 40 % → 48 %	Acordar capacidad y umbral	Dirección médica
Usar la raza para fijar umbrales	Gobernar	ThresholdOptimizer la necesita	Consulta legal y ética	Comité de ética
Pacientes repetidos entre entrenamiento y prueba	Mapear	Sin identificador de paciente	Partir por paciente	Ciencia de datos

Dos cambios, dos formas de verlos

$$\text{PSI} = \sum_i (p_i - q_i) \ln(p_i/q_i) \quad < 0.1 \text{ estable} \cdot 0.1-0.25 \text{ revisar} \cdot > 0.25 \text{ actuar}$$


Drift de datos

Cambian las entradas. Se ve de inmediato: PSI, prueba KS, tasa de seleccionados.

Drift de concepto

Cambia la relación entrada → resultado. Solo se ve con etiquetas, a veces semanas después.

El PSI no ve el drift de concepto



Qué, cada cuánto, con qué umbral, quién y qué hace

Qué se mide	Frecuencia	Umbral	Responsable	Respuesta
PSI del puntaje y de las 5 variables más importantes	semanal	> 0.1 revisar · > 0.25 incidente	MLOps	Analizar; si persiste, reentrenar y revalidar
Tasa de seleccionados	semanal	fuera de 35–45 %	MLOps + programa	Ajustar el umbral a la capacidad
Precisión y recall con etiquetas	mensual	caída > 5 puntos	Ciencia de datos	Investigar drift de concepto; reentrenar
TPR por grupo, con intervalos	trimestral	brecha > 0.10 sin superposición	Comité de ética	Auditoría y mitigación

Cada versión se registra en MLflow con su Model Card y su plan.

BLOQUE 5 · 2:35–3:00

Los exámenes

Escrito el sábado 24/10 · práctico hasta el 24/10, 23:59.

30 ítems basados en casos

Unidad	Ítems
U1 · Fundamentos, métricas, fuga	8
U2 · Supervisado y selección de modelos	8
U3 · No supervisado y anomalías	7
U4 · Ética, sesgo, calidad, documentación	7

- Cuestionario en el LMS, una sola apertura; ítems al azar de un banco de ≈ 90 .
- Casos breves, lectura de gráficos y tablas (matriz de confusión, curvas, silhouette, calibración, `MetricFrame`), errores en fragmentos de código, elección justificada.
- 7 de comprender, 13 de aplicar e interpretar, 10 de analizar y evaluar.

Clasificación de ingresos con ACS Income

- Datos del censo de EE. UU. (ACS), versión ACSIncome de Ding et al. (2021): ingreso > 50 000 USD; sensibles: sexo y raza.
- **Tu variante:**
`python variante.py <tu código>` te asigna uno de 36 estados y una semilla.
- Pipeline sin fuga, ≥ 3 modelos con búsqueda y MLflow, calibración y umbral.
- Auditoría con `MetricFrame` y mitigación si corresponde; explicabilidad global y local.
- Model Card, Datasheet, plan de monitoreo y registro de riesgos (NIST).

Python

```
from src.datos import (cargar_datos, grupos_sensibles,
                        particion)

X, y = cargar_datos("NC", semilla=3312)      # tu variante
A = grupos_sensibles(X)                      # sexo y raza
X_tr, X_te, y_tr, y_te = particion(X, y, semilla=3312)
```

Cómo se evalúa

Criterio	Pts
Reproducibilidad, estructura y prueba mínima (<code>pytest</code>)	10
Datos y pipeline sin fuga	15
Comparación de modelos, búsqueda y selección justificada	20
Seguimiento de experimentos (MLflow)	10
Auditoría de equidad y mitigación	15
Explicabilidad	10
Model Card y Datasheet	10
Plan de monitoreo y registro de riesgos	10

Estructura y prueba mínima

bash

```
examen-practico/
├─ variante.py          # estado y semilla
├─ src/datos.py         # carga, sensibles, partición
├─ src/pipeline.py      # tu pipeline
├─ tests/               # pytest: datos y pipeline
├─ notebooks/examen_practico.ipynb
└─ reports/             # model_card, datasheet,
                        # plan_monitoreo, registro_riesgo
                        # informe, prompts
```

bash

```
# en la carpeta examen-practico/
pytest -q
# ..... 7 passed

mlflow ui --backend-store-uri sqlite:///mlflow.db
```

Una semana, dos exámenes

- 1 **Hoy, sáb 17/10:** se publica el examen práctico; laboratorio E4.2 como ensayo.
- 2 **Hasta el vie 23/10:** simulacro Q4, guía de autoevaluación y revisión entre pares del avance.
- 3 **Sáb 24/10:** examen escrito (90 min) · entrega del práctico hasta las 23:59.

Antes de irte, responde en el chat

- 1 En tu variante de ACS Income, ¿qué error perjudica más a una persona: el falso positivo o el falso negativo? ¿Qué métrica de equidad auditarás?
- 2 ¿Qué señal de tu plan de monitoreo detectaría un drift de concepto?

A CONTINUACIÓN · LABORATORIO GUIADO DE 1.5 H

Ahora, a auditar un modelo de verdad

E4.2 · Nivel 3: reingreso hospitalario con Fairlearn Exámenes · sáb 24/10